Implementação de uma “Aplicação” de Recomendações de Filmes

1. Introdução

Este relatório descreve a implementação de uma aplicação de recomendações de filmes desenvolvida em MATLAB.O programa utiliza uma combinação de técnicas, sendo estas o Filtro de Bloom, Naïve Bayes e MinHash, para conseguir alcançar os objetivos esperados.

O objetivo principal da aplicação é:

1. Verificar se um filme já está armazenado no sistema.
2. Estimar uma avaliação para novos filmes utilizando o Naive Bayes.
3. Sugerir filmes similares com base em características textuais como título, sinopse e gêneros.

2. Estrutura e Funcionamento do Código

2.1. Carregamento e Estruturação dos Dados

Os dados são carregados de um arquivo CSV (`movie_dataset.csv`) e estruturados em um array de structs chamado `movies`. Este array contém as seguintes informações relevantes:

- **Campos armazenados:** `genre`, `id`, `overview`, `title`, `average_rating`, `director`.
- **Filtragem:** Filmes com valores ausentes em qualquer um dos campos não serão guardados.

A estruturação garante que apenas filmes válidos sejam processados nas etapas subsequentes.

2.2. Filtro de Bloom

Um **Filtro de Bloom** é implementado para verificar rapidamente a presença de um filme no sistema:

- **Inicialização:** Um array binário (`FB`) é inicializado para armazenar os hashes.
- **Inserção de Filmes no Filtro:** Os filmes são transformados em strings únicas combinando seus campos principais e inseridos no filtro utilizando múltiplas funções de hash.
- **Verificação:** A presença de um filme no filtro é determinada verificando os bits associados a seus hashes.

Para calcular a taxa de falsos positivos apliquei a seguinte fórmula:

$$taxa\ de\ falsos\ positivos\ =\ número\ de\ falsos\ positivos\ detectados\ /\ length(movies)\ *\ 100$$

Substituindo os valores, pelos que usei quando testei o bloom filter no ficheiro project.m obtive uma taxa de 14,70%

Como mostrado acima, o Filtro de Bloom apresenta falsos positivos, ou seja, pode indicar que um filme está presente quando não está. Isso é uma limitação inerente da técnica. Uma possível forma de reduzir estes casos seria em vez de juntar todas as características do filme numa string, é guardar cada característica numa coluna individual no bloom filter.

2.3. Estimativa de Avaliação com Naive Bayes

O **Naive Bayes** é utilizado para prever uma avaliação média para novos filmes com base em seus géneros e diretor:

- **Preparação dos Dados:**
  - Vetores binários indicam a presença de cada género e diretor para os filmes existentes.
  - As avaliações médias dos filmes são registradas.
- **Probabilidades Condicionais:** Calculadas para cada combinação de avaliação, género e diretor.
- **Previsão:** Dado um filme novo, sua avaliação é estimada combinando as probabilidades do Naive Bayes para os géneros e diretor fornecidos.

Uma possível limitação nesta parte seria se o utilizador inserir géneros e/ou diretores desconhecidos, assim levando a uma avaliação que poderá não estar adequada.

2.4. Sistema de Recomendação com MinHash

Um sistema de recomendação baseado em **MinHash** sugere filmes similares ao fornecido:

- **Shingles:** Textos do título, sinopse e géneros de cada filme são divididos em conjuntos de substrings (shingles) de tamanho fixo, neste projeto usei o tamanho 3.
- **Assinaturas MinHash:** Cada filme é representado por uma assinatura de hashes gerados a partir de seus shingles.
- **Comparação:** A distância de Jaccard entre as assinaturas do filme de entrada e os filmes armazenados é calculada para determinar a similaridade.
- **Recomendações:** Os três filmes mais similares são apresentados ao utilizador.

3. Resultados do código da app_final.m

No código `app_final.m`, foi implementada uma função principal (`main`) que integra as funcionalidades de cada módulo mencionado neste relatório. Para a execução correta do programa, é necessário inicialmente carregar e estruturar os dados, rodando todas as funções auxiliares antes de executar a `main`.

Com os dados devidamente carregados, ao executar a função principal, o programa solicita ao utilizador informações sobre um filme, incluindo título, sinopse, gêneros e diretor. A partir dessas informações, o fluxo segue os seguintes passos:

1. **Verificação no Filtro de Bloom:**
   O programa verifica se o filme já é conhecido pelo sistema utilizando o Filtro de Bloom. Se o filme for encontrado, seria esperado que a avaliação armazenada fosse exibida. Contudo, essa funcionalidade não foi implementada na versão atual do código; o sistema apenas informa se o filme está presente ou não no filtro.
2. **Estimativa de Avaliação com Naïve Bayes:**
   Caso o filme não seja encontrado no Filtro de Bloom, o programa estima sua avaliação média utilizando o modelo Naïve Bayes.
3. **Recomendações com MinHash:**
   Independentemente de o filme estar presente ou não no Filtro de Bloom, o sistema sugere três filmes similares com base nas características fornecidas pelo utilizador. Essa funcionalidade utiliza a técnica de MinHash para identificar similaridades.

Autor: Daniel Baptista de Oliveira, 115359, P5